


Άσκηση 1

1.a.



Με βάση το παραπάνω ιστόγραμμα, τα δεδομένα **δεν** είναι κατάλληλα για τις μεθόδους συμπερασματολογίας που γνωρίζουμε.

Καταρχάς, έχουμε έλλειψη κανονικότητας καθώς η κατανομή των δεδομένων εμφανίζει έντονη ασυμμετρία προς τα δεξιά, κάτι που αποκλίνει από την απαίτηση της κανονικότητας. Επιπλέον, η τιμή 284 χαρακτηρίζεται ως ακραία τιμή η οποία επηρεάζει την μέση τιμή και την τυπική απόκλιση.

1.β.

1.β

$$n=20$$

Μέση τιμή

$$\bar{x} = \frac{\sum x_i}{n}$$

$$\bar{x} = \frac{82+55+58+\dots+83+38}{20} = 77.7 \text{ ms}$$

Συνολική απόκλιση

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}$$

$$s = 55.55$$

Το διάστημα εμπιστοσύνης είναι 95% άρα

$$\alpha = 0.05$$

$$\frac{\alpha}{2} = 0.025$$

$$\text{Βαθμοί Ελευθερίας} = df = n-1 = 20-1 = 19$$

$$\text{Άρα } t_{\alpha/2} = 2.093$$

Έχουμε λοιπόν

$$\bar{x} \pm t_{\alpha/2} \cdot \frac{s}{\sqrt{n}} \Rightarrow 2.093 \cdot \frac{55.55}{\sqrt{20}} = 25.99$$

Επομένως

$$\bar{x} \pm t_{\alpha/2} \cdot \frac{s}{\sqrt{n}} \begin{cases} 77.7 + 25.99 = 103.69 \\ 77.7 - 25.99 = 51.71 \end{cases}$$

Το διάστημα εμπιστοσύνης για την μέση τιμή είναι $[51.71, 103.69]$

Άσκηση 2

a.

Στην προκειμένη περίπτωση, το λάθος βρίσκεται στον υπολογισμό της τυπικής απόκλισης του δειγματικού μέσου, όπου από $12/20$ θα έπρεπε να είναι $12/(20^{1/2})$.

b.

Η υπόθεση δεν αφορά δείκτες του δείγματος (όπως ο $\bar{x}$) αλλά παραμέτρους του πληθυσμού.

c.

Το δείγμα δεν υποστηρίζει την υπόθεση του $H_a: \mu > 54$ καθώς η τιμή του είναι χαμηλότερη από την μέση τιμή της μηδενικής υπόθεσης

d.

Είναι λάθος η απόρριψη της μηδενικής υπόθεσης, καθώς το p-value είναι μεγαλύτερο από το επίπεδο σημαντικότητας.

Άσκηση 3

$$H_0: \mu = \mu_0$$

$$z = 1.34$$

a) Με την χρήση της κανονικής κατανομής για το $z = 1.34$ έχουμε ότι:

$$P(Z > 1.34) = 1 - P(Z \leq 1.34) = 1 - 0.9098773 = 0.0901227$$

Αρα το p value για την εναλλακτική υπόθεση

$H_a: \mu > \mu_0$ είναι ίσο με 0.0901227

b) Από α γνωρίζουμε ότι

$$P(Z \leq 1.34) = 0.9098773$$

Αρα το p value για την εναλλακτική υπόθεση $H_a: \mu < \mu_0$

θα είναι ίσο με 0.9098773

c) Το p value θα είναι διπλάσιο γιατί πρόκειται για 2 κατευθύνσεις

$$p \text{ value} = 2 \cdot P(Z > 1.34) \Rightarrow p \text{ value} = 0.1802454$$

Επομένως το p value για την εναλλακτική υπόθεση

$H_a: \mu \neq \mu_0$ θα είναι 0.1802454

Άσκηση 4

a.

Η τιμή 30 δεν περιέχεται στο 95% διάστημα εμπιστοσύνης για την μέση τιμή μ , επειδή το p value είναι μικρότερο από το επίπεδο σημαντικότητας 0.05 που σημαίνει ότι απορρίπτεται η μηδενική υπόθεση.

b.

Η τιμή 30 δεν περιέχεται στο 90% διάστημα καθώς το p value είναι μικρότερο από το επίπεδο σημαντικότητας το οποίο είναι 0.10. Επομένως, απορρίπτεται και σε αυτήν την περίπτωση η μηδενική υπόθεση

Άσκηση 5

a.

```
> upper_bound <- mean_weight + error_margin
> cat("95% Διάστημα Εμπιστοσύνης για τον μέσο βάρος:\n")
95% Διάστημα Εμπιστοσύνης για τον μέσο βάρος:
> cat("Κάτω όριο:", round(lower_bound, 2), "\n")
Κάτω όριο: 64.18
> cat("Άνω όριο:", round(upper_bound, 2), "\n")
Άνω όριο: 77.98
> |
```

Το διάστημα εμπιστοσύνης 95% για το μέσο βάρος των ενηλίκων κατοίκων Αθήνας είναι το [64.18, 77.98]

b.

```
> cat("80% Διάστημα Εμπιστοσύνης για τη διαφορά μέσου βάρους (Α - Γ):\n")
80% Διάστημα Εμπιστοσύνης για τη διαφορά μέσου βάρους (Α - Γ):
> cat("Διαφορά μέσου βάρους:", round(mean_diff, 2), "\n")
Διαφορά μέσου βάρους: 15.86
> cat("Κάτω όριο:", round(lower_bound, 2), "\n")
Κάτω όριο: 7.45
> cat("Άνω όριο:", round(upper_bound, 2), "\n")
Άνω όριο: 24.27
> |
```

το 80% διάστημα εμπιστοσύνης για τη διαφορά του μέσου βάρους μεταξύ ανδρών και γυναικών (ενηλίκους κατοίκους Αθηνών) είναι μεταξύ [7.45 , 24.27]

Άσκηση 6

6.

α)

Το δείγμα είναι ισοκύβητο με την χρήση μεθόδων στατιστικής συμπερασματικής καθώς βλέπουμε πως απορρίπτονται σε αυτή έλκοντα ή κανονική κατανομή με ισχύον οι προϋποθέσεις ότι το δείγμα είναι τυχαίο και η κατανομή σφαιρική με σφαιρικές τιμές από την κανονική κατανομή.

β)

μέση τιμή:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{110}{20} = 5,5 \quad \text{όρα} \quad \bar{x} = 5,5$$

$$n = 20$$

$$\sum x_i = 5.7 + 4.6 + 6.4 + 6.3 + 6.9 + 5.2 + 4.9 + 5.4 + 4.9 + 5.6 + 5.4 + 5.3 + 4.9 + 5.1 + 5.0 + 6.0 + 6.3 + 5.4 + 5.3 + 5.4 = 110$$

ωσμή συνάρτηση S:

$$S = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}} = \sqrt{\frac{n \cdot \sum x_i^2 - (\sum x_i)^2}{n \cdot (n-1)}} = \sqrt{\frac{20 \cdot 605,9 - (110)^2}{20 \cdot (20-1)}}$$

$$= \sqrt{\frac{12 \cdot 118 - 12100}{380}} = \sqrt{\frac{18}{380}} = \sqrt{0,04737} \approx 0,60088$$

$$\sum x_i^2 = (5.7)^2 + (4.6)^2 + (6.4)^2 + (6.3)^2 + (6.9)^2 + (5.2)^2 + (4.9)^2 + (5.4)^2 + (4.9)^2 + (5.6)^2 + (5.4)^2 + (5.3)^2 + (4.9)^2 + (5.1)^2 + (5.0)^2 + (6.0)^2 + (6.3)^2 + (5.4)^2 + (5.3)^2 + (5.4)^2 = 605,9$$



#

$$= 32.49 + 21.16 + 40.96 + 39.69 + 47.61 + 27.04 + 24.01 + 29.16 + 24.01 + 31.36 + 29.16 + 28.09 + 24.01 + 26.01 + 25 + 36 + 39.69 + 29.16 + 28.09 + 29.16 = 605.9$$

Hypothesis given $\bar{x} = 5,5$ and n small number
 $s = 0.60088$

(C)

Interval estimation 95% for the mean μ

$$\mu = \bar{x} \pm t \cdot \frac{s}{\sqrt{n}}$$

t for 95% confidence interval = 2.093
 and $df = 19$

are

$$\rightarrow \mu = 5,5 + 2.093 \cdot \frac{0.60088}{\sqrt{20}} \quad \text{are} \quad \left(\frac{2.093 \cdot 0.60088}{\sqrt{20}} \approx 1,257 \right) \quad \frac{1,257}{4,472}$$

$$\mu_1 = 5,5 + \frac{1,257}{4,472} = 5,5 + 0,281 \approx 5,781$$

$$\mu_2 = 5,5 - 0,281 \approx 5,219$$

Are 95% confidence interval are $[5,219, 5,781]$

Άσκηση 7.

```
> synergeio <- c(500, 1550, 1250, 1300, 750, 1000, 1250, 1300, 800, 2500)
> expert <- c(400, 1500, 1300, 1300, 800, 800, 1000, 1100, 650, 2200)
> result <- t.test(synergeio, expert, paired = TRUE, alternative = "greater")
> print(result)
```

Paired t-test

```
data: synergeio and expert
t = 2.9132, df = 9, p-value = 0.008611
alternative hypothesis: true mean difference is greater than 0
95 percent confidence interval:
 42.63653      Inf
sample estimates:
mean difference
      115
```

Από τα πάνω συμπεράνουμε πως δεν ισχύει η μηδενική υπόθεση H_0 και ότι το συνεργείο υπερεκτιμά τις ζημιές σε σύγκριση με τον εμπειρογνώμονα.

Άσκηση 8.

α.

```
> male_heights <- data$height[data$gender == "M"]
> female_heights <- data$height[data$gender == "F"]
> mean_diff <- mean(male_heights, na.rm = TRUE) - mean(female_heights, na.rm = TRUE)
> se_diff <- sqrt(var(male_heights, na.rm = TRUE) / length(na.omit(male_heights)) +
+               var(female_heights, na.rm = TRUE) / length(na.omit(female_heights)))
> ci_95 <- mean_diff + c(-1, 1) * qnorm(0.975) * se_diff
> cat("Διαφορά μέσων:", mean_diff, "\n")
Διαφορά μέσων: 0.1270199
>
> cat("95% Διάστημα εμπιστοσύνης:", ci_95, "\n")
95% Διάστημα εμπιστοσύνης: 0.1041659 0.149874
> |
```

Το διάστημα εμπιστοσύνης 95% για τη διαφορά του μέσου ύψους μεταξύ ανδρών και γυναικών φοιτητών πληροφορικής του ΟΠΑ με διαφορά μέσων ~ 0.127 είναι μεταξύ των $[0.104, 0.1498]$

β.

Κάνουμε την Μηδενική υπόθεση (H_0) δηλαδή ότι μέσος βαθμός των ανδρών φοιτητών στις Πιθανότητες είναι ίσος με τον μέσο βαθμό των γυναικών φοιτητριών και την Εναλλακτική υπόθεση (H_a) δηλαδή ότι μέσος βαθμός των ανδρών φοιτητών στις Πιθανότητες είναι μεγαλύτερος από τον μέσο βαθμό των γυναικών φοιτητριών.


```

> male_grades <- data$prob[data$gender == "M"]
> female_grades <- data$prob[data$gender == "F"]
>
> t_test_b <- t.test(male_grades, female_grades, var.equal = FALSE)
> cat("t-statistic:", t_test_b$statistic, "\n")
t-statistic: 0.5992488
> cat("p-value:", t_test_b$p.value, "\n")
p-value: 0.5505579
> |

```

μετα την R βλέπουμε πως έχουμε Το $p\text{-value}=0.5506$ το οποίο είναι πολύ μεγαλύτερο από το επίπεδο σημαντικότητας 5% (0.05) όπου έχουμε το οποίο σημαίνει πως δεν έχουμε αρκετά στοιχεία για να απορρίψουμε το H_0 . Άλλα δεν υπάρχει στατιστικά σημαντική διαφορά μεταξύ των μέσων βαθμών ανδρών και γυναικών στις πιθανότητες στο επίπεδο σημαντικότητας 5% και άρα δεν μπορούμε να πούμε πως οι άνδρες επιτυγχάνουν μεγαλύτερο μέσο βαθμό από τις γυναίκες.

C.

```

> grades_probabilities <- data$prob
> grades_math1 <- data$math
>
> paired_dataset <- na.omit(data.frame(grades_probabilities, grades_math1))
> paired_t_test <- t.test(paired_dataset$grades_probabilities, paired_dataset$grades_math1, paired = TRUE)
>
> cat("t-statistic:", paired_t_test$statistic, "\n")
t-statistic: -3.114955
> cat("p-value:", paired_t_test$p.value, "\n")
p-value: 0.002331974

```

Αφού η $p\text{-value}$ είναι μικρή το οποίο είναι μια ισχυρή απόδειξη κατά της H_0 . Άρα μας αποδεικνύει πως υπάρχει διαφορά μεταξύ των μέσων όρων του βαθμού στις Πιθανότητες και του βαθμού στα Μαθηματικά 1-μεταξύ των φοιτητών που έχουν πάρει ή θα έπαιρναν το μάθημα «Στατιστική στην Πληροφορική».