

Άσκηση 1 / α.

ομάδα δεδομένων 1

stemplot

```

30 | 3
31 | 0 1
32 | 1 6 7
33 | 4 6
34 | 2 5

```

boxplot


$$Q_2 = \frac{32.6 + 32.7}{2} = 32.65$$

$$Q_1 = 31.1$$

$$IQR = Q_3 - Q_1 = 33.6 - 31.1 = 2.5$$

$$Q_3 = 33.6$$

$$[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR] = [27.3, 37.3]$$



ομάδα δεδομένων 2

stemplot

```

0 | 0 0 2 8
1 | 2 4
3 | 2
4 | 2
6 | 4
9 | 0

```

boxplot


$$Q_2 = \frac{1.2 + 1.4}{2} = 1.3$$

$$Q_1 = 0.2$$

$$IQR = 4.2 - 0.2 = 4$$

$$Q_3 = 4.2$$

$$[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR] = [-5.8, 10.2]$$



ομάδα δεδομένων 3

stemplot

```

0 | 0 1 6 8
1 | 0 3 5 6 7 7 8 8
2 | 0 0 1 5 6 0
3 | 0 5 9
4 | 0 1 3 4 6 8
5 | 2 4 8 9 9
6 | 0 6
8 | 1 6 7 8 9
9 | 4 6

```

boxplot


$$Q_2 = \frac{39 + 40}{2} = 39.5$$

$$Q_1 = 17.5$$

$$IQR = 59 - 17.5 = 41.5$$

$$Q_3 = 59$$

$$[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR] = [-44.7, 121.2]$$



B) Στην πρώτη ομάδα δεδομένων, η κατανομή, συνοψίζεται καλύτερα με την χρήση της μέσης τιμής και της τυπικής απόκλισης καθώς υπάρχουν συμμετρικές κατανομές χωρίς ακραίες τιμές. Στην δεύτερη ομάδα δεδομένων παρατηρούμε ασυμμετρία στις τιμές και είναι ακραίες. Επομένως, η σύνοψη με τους 5 αριθμούς θα είναι η καταλληλότερη. Τέλος, στην τρίτη ομάδα δεδομένων, υπάρχουν ακραίες τιμές (81,86,...,94,96) οπότε θα προτιμήσουμε την σύνοψη 5 αριθμών.

C) Η προσέγγιση κατανομής των δεδομένων από μια καμπύλη πυκνότητας της Κανονικής κατανομής θα είναι πιο ακριβής στην πρώτη ομάδα δεδομένων καθώς υπάρχουν συμμετρικές κατανομές. Δεν θα προτιμήσουμε αυτή την προσέγγιση στις άλλες 2 ομάδες δεδομένων.

Άσκηση 2

A) Τα δεδομένα προέρχονται από την ιστοσελίδα vgchartz.com αλλά τα βρήκαμε από το kaggle.com, συλλέχθηκαν με το BeautifulSoup σε Python, και περιέχουν πληροφορίες για πωλήσεις βιντεοπαιχνιδιών

που ξεπερνούν τις 100.000 κόπιες παγκοσμίως .Το Video Game Sales Dataset περιέχει τις εξής κατηγορίες/περιπτώσεις:Πωλήσεις στη Βόρεια Αμερική,

Πωλήσεις στην Ευρώπη,Πωλήσεις στην Ιαπωνία,Πωλήσεις στον υπόλοιπο κόσμο,Συνολικές πωλήσεις παγκοσμίως .

B)Κατηγορικές μεταβλητές:

Name: Όνομα του παιχνιδιού.

Platform: Πλατφόρμα κυκλοφορίας (π.χ., PC, PS4).

Genre: Είδος παιχνιδιού (π.χ., δράση, αθλητικά).

Publisher: Εκδότης παιχνιδιού.

Ποσοτικές μεταβλητές:

Rank: Η συνολική κατάταξη βάσει πωλήσεων.

Year: Έτος κυκλοφορίας.

NA_Sales: Πωλήσεις στη Βόρεια Αμερική (σε εκατομμύρια).

EU_Sales: Πωλήσεις στην Ευρώπη (σε εκατομμύρια).


JP_Sales: Πωλήσεις στην Ιαπωνία (σε εκατομμύρια).

Other_Sales: Πωλήσεις στον υπόλοιπο κόσμο (σε εκατομμύρια).

Global_Sales: Συνολικές πωλήσεις παγκοσμίως (σε εκατομμύρια).


Αυτό το dataset περιέχει 16,598 εγγραφές με στατιστικά πωλήσεων για δημοφιλή βιντεοπαιχνίδια.

C.




Ραβδόγραμμα του Genre, είδος κάθε παιχνιδιού και πόσα ανά είδος έχουν φτιαχτεί, έχει πολυμορφική κατανομή καθώς τα δεδομένα για αυτό το ραβδόγραμμα προέρχονται από διαφορετικών ειδών βιντεοπαιχνίδια και έτσι υπάρχουν πολλές κορυφές. Δεν υπάρχουν ατυπικά σημεία.


Συχνότητα Εκδοτών Παιχνιδιών



Ραβδόγραμμα για τους Publisher, δηλαδή των εκδοτών των παιχνιδιών και πόσα έχουν κυκλοφορήσει. Η κατανομή των μεταβλητών είναι πολυμορφική καθώς όπως και στο Genre υπάρχουν διαφορετικών ομάδων δεδομένα και για αυτό υπάρχουν πολλές κορυφές στο διάγραμμα. Δεν υπάρχουν ατυπικά σημεία.




Ραβδόγραμμα για τα Platforms, μας δείχνει πόσα παιχνίδια βγήκαν ανά κονσόλα (δεδομένου ότι δεν έχει βγει κάποιο video game σε 2 και πάνω κονσόλες). Η κατανομή των μεταβλητών είναι πολυμορφική καθώς υπάρχουν δεδομένα από πολλές διαφορετικές ομάδες και για αυτό υπάρχουν πολλές κορυφές στο διάγραμμα. Δεν υπάρχουν ατυπικά σημεία.




Ραβδόγραμμα για το EU_SALES, για τις πωλήσεις βιντεοπαιχνιδιών στην Ευρώπη. Η μορφή της καμπύλης είναι εκθετική και αυτό προκύπτει πιθανών από το γεγονός πως πολλά βιντεοπαιχνίδια θα κάνουν κακές πωλήσεις, κάποια θα κάνουν λίγο παραπάνω , λίγα θα κάνουν ok πωλήσεις και ελάχιστα θα πουληθούν πολύ. Παρατηρούμε κάποια ατυπικά σημεία μεταξύ των σημείων 0.57 και 0.6 καθώς και 0.63 και 0.66 πιθανών γιατί πολύ ελάχιστα βιντεοπαιχνίδια μπορεί να σπάσαν ρεκόρ πωλήσεων ανά τα χρόνια.

Συχνότητα Πωλήσεων στη Βόρεια Αμερική




Ραβδόγραμμα για το NA_SALES, για τις πωλήσεις βιντεοπαιχνιδιών στην Βόρεια Αμερική. Η μορφή της καμπύλης είναι εκθετική και αυτό προκύπτει πιθανών από το γεγονός πως πολλά βιντεοπαιχνίδια θα κάνουν κακές πωλήσεις, κάποια θα κάνουν λίγο παραπάνω , λίγα θα κάνουν ok πωλήσεις και ελάχιστα θα πουληθούν πολύ. Παρατηρούμε ατυπικά σημεία μεγαλύτερα της Ευρώπης μεταξύ των σημείων 1.65 και 1.76 καθώς και 1.88 και 1.99 αλλά κατά κύριο λόγο στο 1.99 και μεταξύ 2.1 με 2.22 πιθανών γιατί πολύ ελάχιστα βιντεοπαιχνίδια μπορεί να σπάσαν ρεκόρ πωλήσεων ανά τα χρόνια.

Συχνότητα πώλησεων στην Ιαπωνία




Ραβδόγραμμα για το JP_SALES, για τις πωλήσεις βιντεοπαιχνιδιών στην Ιαπωνία. Η μορφή της καμπύλης είναι εκθετική και αυτό προκύπτει πιθανών από το γεγονός πως πολλά βιντεοπαιχνίδια θα κάνουν κακές πωλήσεις, κάποια θα κάνουν λίγο παραπάνω , λίγα θα κάνουν ok πωλήσεις και ελάχιστα θα πουληθούν πολύ. Παρατηρούμε ατυπικά σημεία κυρίως 0.63 και μεταξύ 0.7 και 0.77 πιθανών γιατί πολύ ελάχιστα βιντεοπαιχνίδια μπορεί να σπάσαν ρεκόρ πωλήσεων ανά τα χρόνια.

Συχνότητα Πωλήσεων στον Υπόλοιπο Κόσμο




Ραβδόγραμμα για το Other_Sales, για τις πωλήσεις βιντεοπαιχνιδιών στον υπόλοιπο κόσμο, πέρα Ευρώπης, Β. Αμερικής και Ιαπωνίας. Η μορφή της καμπύλης είναι εκθετική και αυτό προκύπτει πιθανών από το γεγονός πως πολλά βιντεοπαιχνίδια θα κάνουν κακές πωλήσεις, κάποια θα κάνουν λίγο παραπάνω, λίγα θα κάνουν ok πωλήσεις και ελάχιστα θα πουληθούν πολύ. Παρατηρούμε ατυπικά σημεία κυρίως μεταξύ στο 0.5 και 0.55, στο 0.6 και μεταξύ 0.6 και 0.65 καθώς και μεταξύ 0.75 και 0.8 πιθανών γιατί πολύ ελάχιστα βιντεοπαιχνίδια μπορεί να σπάσαν ρεκόρ πωλήσεων ανά τα χρόνια.

Συχνότητα Συνολικών Πωλήσεων Παγκοσμίως (Zoom In)



Ραβδόγραμμα για το Global_Sales, για τις πωλήσεις βιντεοπαιχνιδιών σε όλο τον κόσμο. Στην πραγματικότητα, έχει κανονική κατανομή καθώς δεν ξεκινάει από το μέγιστο σημείο της από το 0, αλλά μεγιστοποιείται κάπου ανάμεσα στο 0.01 και 0.13 και μετά κατεβαίνει σαν την εκθετική καμπύλη. Πιθανόν αυτό γίνεται αυτό γιατί περισσότερα παιχνίδια πούλησαν λίγο ανάμεσα σε 10000 και 130000 αντίτυπα απ'ότι κάτω από 10000. Παρατηρούμε ατυπικά σημεία κυρίως μεταξύ 3.46 και 3.61 καθώς και το μεγαλύτερο που βρίσκεται μεταξύ 4.23 και 4.42



Ραβδόγραμμα για το Year, Έτος κυκλοφορίας. Έχει κανονική κατανομή το διάγραμμα που κορυφώνεται στο έτος 2009, πολύ πιθανών να υπήρχε κάποια άνθησή στον τομέα των βιντεοπαιχνιδιών εκείνα τα ετη και να βγήκαν παραπάνω βιντεοπαιχνίδια ή η κυκλοφορία της κονσόλας XBOX 360 να το προκάλεσε. Ως ατυπικά σημεία ίσως μπορούμε να αναφέρουμε το N/A που δείχνει τα βιντεοπαιχνίδια που δεν ξέρουμε πότε κυκλοφόρησαν αλλά και για αυτό δεν είναι ουσιαστικά ατυπικό σημείο.

D)

Για τις πωλήσεις της B. Αμερικής:

```
> mean_NA <- mean(data$NA_Sales, na.rm = TRUE)
> sd_NA <- sd(data$NA_Sales, na.rm = TRUE)
> mean_NA
[1] 0.2646674
> sd_NA
[1] 0.816683
> summary(data$NA_Sales)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.0000  0.0000  0.0800  0.2647  0.2400 41.4900
```

Μέση τιμή: 0.2646674

Τυπική απόκλιση: 0.816683

Η σύνοψη 5 αριθμών φαίνεται στο summary.

Για τις πωλήσεις της Ευρώπης:

```

> mean_EU <- mean(data$EU_Sales, na.rm = TRUE)
>
> mean_EU
[1] 0.146652
> sd_EU <- sd(data$EU_Sales, na.rm = TRUE)
> sd_EU
[1] 0.5053512
> summary(data$EU_Sales)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.0000  0.0000   0.0200   0.1467   0.1100  29.0200
> |

```

Μέση τιμή: 0.146652

Τυπική απόκλιση: 0.5053512

Η σύνοψη 5 αριθμών φαίνεται στο summary.

Για τις πωλήσεις στην Ιαπωνία:

```

> mean_JP <- mean(data$JP_Sales, na.rm = TRUE)
> mean_JP
[1] 0.07778166
> sd_JP <- sd(data$JP_Sales, na.rm = TRUE)
> sd_JP
[1] 0.3092906
> summary(data$JP_Sales)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.00000  0.00000   0.00000   0.07778   0.04000  10.22000
.

```

Μέση τιμή: 0.07778166

Τυπική απόκλιση: 0.3092906

Η σύνοψη 5 αριθμών φαίνεται στο summary.

Για τις πωλήσεις εκτός Ευρώπης, Β.Αμερικής και Ιαπωνίας:

```

> mean_other <- mean(data$other_sales, na.rm = TRUE)
> mean_other
[1] 0.04806302
> sd_other <- sd(data$other_sales, na.rm = TRUE)
> sd_other
[1] 0.1885884
> summary(data$other_sales)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.00000 0.00000  0.01000  0.04806  0.04000 10.57000

```

Μέση τιμή: 0.04806302

Τυπική απόκλιση: 0.1885884

Η σύνοψη 5 αριθμών φαίνεται στο summary.

Για τις πωλήσεις γενικά σε όλο τον κόσμο:

```

> mean_global <- mean(data$global_sales, na.rm = TRUE)
> mean_global
[1] 0.5374407
> sd_global <- sd(data$global_sales, na.rm = TRUE)
> sd_global
[1] 1.555028
> summary(data$global_sales)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.0100  0.0600  0.1700  0.5374  0.4700 82.7400

```

Μέση τιμή: 0.5374407


Τυπική απόκλιση: 1.555028

Η σύνοψη 5 αριθμών φαίνεται στο summary.

Σχόλια για τις μεταβλητές:

Η μέση τιμή και τυπική απόκλιση δίνουν χρήσιμες πληροφορίες για τα διαγράμματα αν τα δεδομένα είναι συμμετρικά κατανεμημένα κάτι που σε αυτήν την περίπτωση δεν ισχύει καθώς κατά κύριο λόγο τα διαγράμματα έχουν εκθετική κατανομή. Η σύνοψη πέντε αριθμών είναι πιο χρήσιμη εδώ καθώς υπάρχουν ακραίες τιμές και έχουμε ασύμμετρο διάγραμμα και η διάμεσος και τα τεταρτημόρια μας δείχνουν μια πιο αξιόπιστη εικόνα του κέντρου και της διασποράς των δεδομένων.

Ε)




Θα πρέπει να δούμε τον συντελεστή συσχέτισης για να δούμε αν υπάρχει κάποια αιτιατική συσχέτιση, άμα είναι πολύ θετικό το αποτέλεσμα υπάρχει μεγάλη ενώ αν είναι πολύ αρνητική δεν υπάρχει.

```
> cor(data$Year, data$Global_Sales, use = "complete.obs")  
[1] -0.0747348  
> |
```

Σύμφωνα με το πάνω, δεν υπάρχει καμία αιτιατική σχέση για την αύξηση των πωλήσεων λόγο την χρονιάς. Πολύ πιθανό η γενική αύξηση βιντεοπαιχνιδιών να οφείλετε σε άλλους παράγοντες πχ ανάπτυξη τεχνολογίας και ψηφιακών πλατφορμών αγοράς βιντεοπαιχνιδιών όπως το Steam.

Άσκηση 3

Α) Χρησιμοποιούμε τις τιμές του βάρους και το μέγεθος των παππουτσιών. Ως προς τη μορφή του διαγράμματος, τα δεδομένα φαίνονται να σχηματίζουν ομάδες. Οι δύο μεταβλητές έχουν θετική σχέση, διότι καθώς αυξάνεται το ύψος, τόσο αυξάνεται και το μέγεθος των παπουτσιών (εμφανίζονται όμως outliers). Τέλος, τα σημεία είναι διάσπαρτα μεταξύ τους, επομένως η σχέση τους είναι ασθενής.



B) Ο συντελεστής συσχέτισης είναι 0.7212048.

