



Άσκηση 3 σε ποσοίς

① ②

$$n = 50$$

$$x = 29$$

$$p = \frac{x}{n} = \frac{29}{50}$$

29 υπέρνες

$$\alpha = 0.05$$

$$\text{Τοποκ. σφάλμα} = SE = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{\frac{29}{50} \left(1 - \frac{29}{50}\right)}{50}}$$

$$= \sqrt{\frac{\frac{29}{50} \cdot \frac{21}{50}}{50}} = \sqrt{\frac{609}{125000}} = \sqrt{0,004872}$$

$$\approx 0,0697$$

$$z = 1.96$$

$$\text{Διάστημα εμπιστοσύνης} = p \pm z \cdot SE = \frac{29}{50} \pm 0.0697 \cdot 1.96$$

$$= \frac{29}{50} \pm 0,136 = 0,58 \pm 0,136 = 0,716$$

$$\parallel 0,58 - 0,136 = 0,444$$

Άρα το διάστημα εμπιστοσύνης 95% είναι (0,444, 0,716)

β)

Μυθιστόνη υπόθεση (H_0): Το νόμισμα είναι δίκαιο, δηλαδή η πιθανότητα εμφάνισης κεφαλής είναι $p=0.5$

Εναλλακτική υπόθεση (H_1): Το νόμισμα δεν είναι δίκαιο, δηλαδή $p \neq 0.5$

$$p_0 = \frac{25}{50}$$

$$Z_{\text{score}} = \frac{p - p_0}{SE} = \frac{\frac{29}{50} - \frac{25}{50}}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{\frac{4}{50}}{\sqrt{\frac{0.5 \cdot 0.5}{50}}} = \frac{0.08}{0.098} = 0.816$$

$$\approx 0.114$$

$$Z_{\text{critical}} = 1.96$$

Αφού το zscore μικρότερο του z critical δεν μπορούμε να απορρίψουμε την μηδενική υπόθεση (H_0).

$$\text{c) } E = Z_{\alpha} \cdot \sqrt{\frac{p(1-p)}{n}} \Rightarrow 0.01 = 1.96 \cdot \sqrt{\frac{0.5(1-0.5)}{n}}$$

$$\left(\frac{0.01}{1.96} \right)^2 = \frac{0.25}{n} \Rightarrow \left(\frac{1}{196} \right)^2 = \frac{0.25}{n} \Rightarrow \frac{1}{38416} = \frac{0.25}{n}$$

$$\frac{1}{38416} = \frac{0.25}{n} \Rightarrow \frac{2500n}{2800} = \frac{23395344}{2800} \Rightarrow$$

$$n = 9358,137$$

Άρα θα έπρεπε να γίνει 9359 πειράς για να είναι μικρότερο από 1% το.

(2)

$$n = \frac{Z^2 \cdot p(1-p)}{E^2}$$

$$n = 1100$$

$Z = 1,96$ αφού έχουμε 2 βαθμούς ελευθερίας με επίπεδο εμπιστοσύνης 95%

$$E = 0.03 \text{ αφού } 3\% \text{ περιθώριο σφάλματος}$$

$p = 0.5$ η απάντηση της αντιστοίχης ομάδας είναι ίση με το μέγιστο επί το 50%

Στην Ελλάδα χρειάζεστε περίπου 1100 άτομα με μέσο εμπιστοσύνη 95% και 3% περιθώριο σφάλματος
Σας ΗΠΑ χρειάζεστε περίπου x από 300 άτομα με μέσο εμπιστοσύνη 95% και 3% περιθώριο σφάλματος

Επειδή και οι δύο χώρες οι μεταβλητές (επίπεδο εμπιστοσύνης και περιθώριο σφάλματος) είναι ίσες από με αυτή απάντηση μας είναι απλά να το βρούμε το x έρε

$$\frac{n_{Ελλάδα}}{n_{ΗΠΑ}} = \frac{n_{ΗΠΑ}}{n_{ΗΠΑ}} \Rightarrow 30000 = n_{ΗΠΑ}$$

$$30000 \cdot 0.03 = 10000 \cdot n_{ΗΠΑ} \Rightarrow$$

$$30000 = n_{ΗΠΑ} \text{ από αυτήν } = \frac{n_{ΗΠΑ}}{n_{Ελλάδα}} = \frac{30000}{1100} = 30$$



Αν οι νέες χρησιμοποιήστε 30 φορές περισσότερο
μεσοπλάθει δείξε για τις ΗΠΑ είναι 3300.

Για να βρούμε το αριθμό ατόμων που θα γίνει η βήμα
το αριθμό ατόμων για κάθε, συμπεριλαμβανομένου

$$n = \frac{z^2 \cdot p(1-p)}{E^2} = \frac{(1.96)^2 \cdot 0.5(1-0.5)}{(0.03)^2} =$$

$$\frac{3.8416 \cdot 0.25}{0.0009} = \frac{0.9604}{0.0009} \approx 1067.1$$

από το αριθμό n για να είναι είναι 1068
και για τις ΗΠΑ = $1068 \cdot 30 = \underline{\underline{32040}}$

Άσκηση 3

α) Ο τύπος $z = (p_1 - p_2) / ((p^*(1-p)(1/n_1 + 1/n_2))^{1/2})$ όπου p_1 και p_2 η αναλογία καπνιστών μεταξύ αντρών/γυναικών, p η συνολική αναλογία καπνιστών.

Σύμφωνα με τον πίνακα συχνοτήτων έχουμε ότι:

Φύλο	Καπνιστής	Συχνότητα
A	Ναι	10
A	Όχι	20
Γ	Ναι	12
Γ	Όχι	18

```
> # Συχνότητες
> men_smokers <- 10
> men_total <- 30
> women_smokers <- 12
> women_total <- 30
>
> # Αναλογίες
> p1 <- men_smokers / men_total
> p2 <- women_smokers / women_total
> p <- (men_smokers + women_smokers) / (men_total + women_total)
>
> # Z-test
> z <- (p1 - p2) / sqrt(p * (1 - p) * (1 / men_total + 1 / women_total))
> z
[1] -0.5357997
```

Η τιμή z δηλώνει ότι η διαφορά των ποσοστών καπνιστών μεταξύ των δύο φύλων δεν είναι στατιστικά σημαντική με επίπεδο σημαντικότητας 0.05.

b)

```
> # 95% Διάστημα εμπιστοσύνης
> se <- sqrt(p1 * (1 - p1) / men_total + p2 * (1 - p2) / women_total)
> diff <- p1 - p2
> lower_bound <- diff - qnorm(0.975) * se
> upper_bound <- diff + qnorm(0.975) * se
> c(lower_bound, upper_bound)
[1] -0.3099503 0.1766170
```

c)

```
> # Πίνακας συνάφειας
> table <- matrix(c(10, 20, 12, 18), nrow = 2, byrow = TRUE)
> colnames(table) <- c("Ναι", "Όχι")
> rownames(table) <- c("Α", "Γ")
> table
      Ναι Όχι
Α    10  20
Γ    12  18
>
> #  $\chi^2$  test
> chisq_test <- chisq.test(table)
> chisq_test

Pearson's Chi-squared test with Yates' continuity correction

data:  table
X-squared = 0.07177, df = 1, p-value = 0.7888
```

d)

```
> p_value <- chisq_test$p.value
> p_value
[1] 0.7887764
```

Δεν υπάρχει στατιστικά σημαντική σχέση μεταξύ φύλου και καπνίσματος στον πληθυσμό που εξετάζουμε.

Και οι 2 μέθοδοι καταλήγουν στο ίδιο συμπέρασμα ότι δεν υπάρχει επαρκής απόδειξη για να υποστηρίξουμε τη σχέση ή τη διαφορά μεταξύ φύλου και καπνίσματος στον πληθυσμό.

Άσκηση 4

α) Θα χρησιμοποιήσουμε τον έλεγχο χ^2 για κατηγορηματικά δεδομένα. Έστω υποθετική κατανομή όπου το ποσοστό των κόκκινων κουφετών είναι ίσο με το ποσοστό των μπλε.

Θα ελέγξουμε το χ^2 υποθέτοντας ότι τα κόκκινα και τα μπλε κουφέτα είναι εξίσου πιθανό να εμφανιστούν.

```
> # Δεδομένα
> observed <- c(19, 15) # Παρατηρούμενα δεδομένα για κόκκινα και μπλε
> expected <- c(17, 17) # Αναμενόμενα δεδομένα αν η κατανομή ήταν ίση
>
> #  $\chi^2$  έλεγχος
> chisq.test(observed, p = expected / sum(expected))

Chi-squared test for given probabilities

data:  observed
X-squared = 0.47059, df = 1, p-value = 0.4927
```

Παρατηρούμε ότι το $p\text{-value} = 0.4927$ είναι μεγαλύτερο από το 0.05 που σημαίνει ότι δεν υπάρχει στατιστικά σημαντική διαφορά στον αριθμό των κόκκινων και μπλε κουφετών. Άρα, **δεν απορρίπτουμε τη μηδενική υπόθεση.**

b) Με την χρήση του ελέγχου χ^2 για τη σύγκριση κατανομών θα έχουμε ότι:

```
> # Παρατηρούμενα δεδομένα
> observed <- c(22, 19, 16, 15, 8)
>
> # Αναμενόμενα δεδομένα από το 2009
> expected_percentages <- c(19.8, 17.8, 17.6, 19.6, 25.2) / 100
> expected <- expected_percentages * sum(observed)
>
> #  $\chi^2$  έλεγχος
> chisq.test(observed, p = expected / sum(expected))

      Chi-squared test for given probabilities

data:  observed
X-squared = 11.613, df = 4, p-value = 0.02048
```

Επομένως απορρίπτουμε την μηδενική υπόθεση καθώς το $p\text{-value} = 0.02048$ (είναι μικρότερο του 0.05) και συμπεραίνουμε πως η κατανομή έχει αλλάξει από το 2009.

c) Χρησιμοποιούμε ξανά τον έλεγχο χ^2 και βλέπουμε τα εξής:

```
> # Δεδομένα για Smarties
> observed_smarties <- c(22, 19, 16, 15, 8)
>
> # Δεδομένα για M&Ms
> observed_mms <- c(10, 12, 20, 9, 5)
>
> #  $\chi^2$  έλεγχος για τη σύγκριση
> chisq.test(observed_smarties, observed_mms)

      Pearson's Chi-squared test

data:  observed_smarties and observed_mms
X-squared = 20, df = 16, p-value = 0.2202
```

Η $p\text{-τιμή}$ είναι μεγαλύτερη από 0.05 που σημαίνει πως υπάρχουν στατιστικά σημαντικές διαφορές μεταξύ των δύο κατανομών και οι αναλογίες είναι διαφορετικές.